

CENTRO UNIVERSITÁRIO DE JOÃO PESSOA - UNIPÊ

PLANO DE CONTINUIDADE E EXECUÇÃO

TRABALHO DE CONCLUSÃO DE CURSO II - 2026.2

Classificação Multiclasse de Eletrocardiogramas de 12 Derivações Utilizando Machine Learning, Balanceamento de Dados e Técnicas de Interpretabilidade

Alunos	Arysson André Oliveira da Luz Paulo Victor Oliveira de Barros Araújo
Orientador	Prof. Dr. Leonardo Angelo Virginio de Souto
Área	Ciência de Dados e Inteligência Artificial
Marco	Execução orientada por entregas; meta interna de conclusão técnica até 31/10/2026 como margem de segurança, sem dependencia de semanas fixas.

João Pessoa - PB
Agosto de 2026

1. Resumo executivo

Este documento organiza a continuidade do TCC I para o TCC II. O ponto de partida é o pipeline reprodutível já desenvolvido com o PTB-XL, incluindo modelos clássicos, redes neurais 1D, balanceamento e interpretabilidade. A formulação multiclasse `strict_single_label` será preservada como referência histórica, enquanto a trilha principal do TCC II adotará a formulação multilabel do benchmark original. O escopo passa a comparar seis papéis experimentais: baselines clássicos, arquiteturas supervisionadas de Helme, convolução temporal moderna, modelos de espaço de estados, aprendizado autossupervisionado e interpretabilidade profunda. A avaliação interna será complementada por validação em um dataset externo selecionado e auditado antes dos experimentos finais.

Meta interna de planejamento

Antecipar todas as atividades possíveis e concluir o núcleo técnico preferencialmente até 31 de outubro de 2026. A data é uma referência interna para preservar tempo de revisão; o andamento será controlado por entregas e critérios de aceite, não por permanencia obrigatória em semanas predefinidas.

2. Identificação e ponto de partida

Tema: Classificação Multiclasse de Eletrocardiogramas de 12 Derivações Utilizando Machine Learning, Balanceamento de Dados e Técnicas de Interpretabilidade.

O TCC I foi preservado no repositório Git por meio da branch tcc1-final, no commit c8e2fb6. O desenvolvimento do TCC II seguirá na branch tcc2-development. Essa separação mantém uma versão auditável do trabalho apresentado e permite evoluir código, experimentos e documentação sem alterar o marco anterior.

Componente já disponível	Situação ao término do TCC I
Dados e rótulos	PTB-XL; superclasses NORM, MI, STTC, CD e HYP; estratégia strict_single_label.
Protocolo	Folds oficiais: treino 1-8, validação 9 e teste 10; teste preservado para avaliação final.
Modelos clássicos	Regressão Logística, SVM, Random Forest, LightGBM e CatBoost, com comparação de SMOTE no treino.
Modelos profundos	CNN simples, ResNet1D leve, InceptionTime 1D adaptada e ResNet1D-SE experimental.
Melhor resultado anterior	InceptionTime 1D adaptada: acurácia 0,7824 e F1 macro 0,6840 em records500.
Interpretabilidade	SHAP e LIME no modelo tabular; Integrated Gradients preparado para a InceptionTime 1D.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

3. Incorporação das observações da banca

As contribuições da banca serão registradas separadamente por avaliador, pois tiveram naturezas distintas. Essa organização não atribui juízo de valor às observações: ela permite demonstrar como cada conjunto de comentários foi conferido e incorporado ao planejamento do TCC II.

Origem	Síntese da contribuição	Encaminhamento no TCC II
Avaliador 1	Durante a arguição, o avaliador perguntou sobre diferentes pontos do projeto. Esses aspectos já estavam bem esclarecidos na versão escrita e já haviam sido trabalhados no desenvolvimento do TCC I.	Manter o conteúdo já desenvolvido e facilitar sua localização no texto e na apresentação, sem tratar como pendências aspectos que já foram implementados e documentados.
Avaliador 2 - avaliação médica	Foi sugerida uma comparação entre o sistema e a avaliação de um médico.	Manter como possibilidade posterior. Uma atividade desse tipo não será denominada validação clínica sem protocolo, padrão de referência, análise estatística e avaliação das exigências éticas.
Avaliador 2 - bases externas	Foi sugerido utilizar uma base brasileira ou outro dataset para avaliar a generalização externa.	Comparar bases candidatas quanto a rótulos, sinais, qualidade de anotação, acesso e viabilidade; selecionar a base somente após essa análise e validação com o orientador.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

Uma base brasileira pode ampliar a relevância populacional do estudo, mas sua origem não garante, por si só, maior qualidade para a tarefa proposta. A escolha deverá considerar cobertura de NORM, MI, STTC, CD e HYP, qualidade da anotação, disponibilidade das 12 derivações e possibilidade de harmonização sem alterar indevidamente o problema de pesquisa.

4. Objetivo do TCC II

Aprofundar a avaliação de abordagens clássicas e profundas para a classificação de superclasses diagnósticas em ECGs de 12 derivações, preservando a formulação `strict_single_label` como referência do TCC I e adotando a formulação `multilabel` para o benchmark principal do TCC II. O estudo reproduzirá arquiteturas originais de Helme e acrescentará famílias ausentes daquele benchmark - TCN, S4 e ECG-JEPA - sob um protocolo comum de seleção interna, avaliação final e validação externa. A comparação será interpretada como confronto entre abordagens experimentais completas, sem atribuir ao teste ou ao dataset externo qualquer papel no ajuste dos modelos.

4.1 Objetivos operacionais

- Selecionar o dataset externo mais adequado após comparar rótulos, 12 derivações, frequência, qualidade das anotações, acesso, risco de sobreposição com dados de pré-treinamento e viabilidade de harmonização.
- Reorganizar o repositório para separar resultados do TCC I, reproduções do benchmark, extensões modernas, avaliação interna e validação externa.
- Reproduzir as arquiteturas supervisionadas selecionadas do `ecg_ptbxxl_benchmarking` na formulação `multilabel` original, registrando versão, commit e adaptações mínimas.
- Reavaliar Regressão Logística, SVM, Random Forest, LightGBM e CatBoost e integrar TCN, S4 e ECG-JEPA como representantes de paradigmas complementares.
- Selecionar configurações exclusivamente pela validação interna, congelar os finalistas e consultar o fold 10 apenas na avaliação final.

- Aplicar o modelo selecionado ao dataset externo escolhido sem reajuste por seus resultados e sem utilizar, como validação externa, uma base que tenha participado do pré-treinamento do modelo.
- Consolidar métricas globais e por classe, variabilidade entre sementes, custo computacional e interpretabilidade pós-hoc com SHAP/LIME no modelo tabular e Integrated Gradients no melhor modelo profundo.

5. Escopo experimental em duas trilhas

Trilha	Pergunta	Dados e protocolo	Resultado esperado
A - Avaliação interna	Quais configurações apresentam melhor desempenho no protocolo do projeto?	PTB-XL; folds 1-8/9/10; multiclasse strict_single_label como referência do TCC I e multilabel de superclasses para reprodução do benchmark.	Resultados separados por formulação, com seleção por validação e métricas adequadas a cada tarefa.
B - Validação externa	O sistema selecionado mantém desempenho em outra fonte de ECG?	Dataset externo escolhido após análise comparativa e auditoria; Georgia é a recomendação principal, condicionada à compatibilidade dos rótulos.	Estimativa de generalização e análise explícita da mudança de domínio.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

Regra de interpretação

A comparação entre modelos clássicos e profundos será apresentada como comparação entre configurações experimentais completas. As entradas, a representação dos dados, a frequência do sinal, a arquitetura e as estratégias de treinamento não são idênticas; portanto, os resultados não isolam apenas o efeito do algoritmo.

6. Modelos finais propostos

Grupo	Modelos	Papel no TCC II
Baseline clássico	Regressão Logística, SVM, Random Forest, LightGBM e CatBoost	Referência baseada em atributos estatísticos; reavaliação controlada em 500 Hz, com a multiclasse do TCC I preservada e adaptação multilabel apenas quando metodologicamente comparável.
Benchmark de Helme	inception1d, xresnet1d101, resnet1d_wang, fcn_wang, LSTM e BiLSTM	Reprodução das implementações originais na tarefa multilabel e em 100 Hz. Wavelet+NN será mantida como referência suplementar se a reprodução integral couber no fluxo.
Convolução temporal moderna	TCN com convoluções dilatadas e conexões residuais	Avaliar se campos receptivos temporais ampliados capturam padrões que não são modelados explicitamente pelas CNNs do benchmark.
Espaço de estados	S4	Representar uma família voltada a dependências longas em sequências, ausente do benchmark original de Helme.

Grupo	Modelos	Papel no TCC II
Aprendizado autossupervisionado	ECG-JEPA; CPC como contingência tecnicamente mais simples	Comparar treinamento do zero com transferência de representações pre-treinadas, controlando a origem dos dados de pré-treinamento.
Interpretabilidade profunda	Integrated Gradients no melhor modelo profundo; ProtoECGNet opcional	Explicar regiões temporais e derivações relevantes para a predição sem interpretar atribuição como causalidade ou validação clínica.
Referência histórica	CNN simples, ResNet1D leve, InceptionTime adaptada e ResNet1D-SE	Preservar os resultados do TCC I para contextualização, sem confundi-los com as reproduções originais ou com o novo benchmark multilabel.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

As arquiteturas de referência serão obtidas do repositório oficial `ecg_ptb_xl_benchmarking`, com a versão exata do código registrada por commit. A reprodução principal seguirá a tarefa multilabel, os alvos multi-hot, a binary cross-entropy e o protocolo original em 100 Hz. TCN, S4 e ECG-JEPA serão incorporados como extensões cientificamente distintas e comparados, sempre que tecnicamente possível, com os mesmos dados, folds e métricas. Experimentos em 500 Hz serão apresentados separadamente e priorizados apenas para os finalistas. ProtoECGNet, ST-MEM, PatchECG e modelos fundacionais de maior porte permanecem como extensões condicionais, não como requisitos do escopo mínimo.

7. Estratégia de treinamento e avaliação

1. Fixar seeds, versões das bibliotecas, hardware utilizado e commit do código antes das execuções finais.
2. Calcular normalização, imputação, pesos de classe e qualquer parâmetro aprendido exclusivamente no treino.
3. Usar o fold 9 para hiperparâmetros, early stopping e escolha de checkpoint. Na referência multiclasse, priorizar F1-score macro; no benchmark multilabel, priorizar AUC macro e reportar Fmax, AUPRC macro e resultados por classe quando disponíveis. O critério de seleção será definido antes de cada família de experimentos e nunca alterado após a consulta ao teste.
4. Limitar o ajuste a uma busca previamente definida; evitar tuning aberto ou repetido após observar o teste.
5. Executar múltiplas sementes nos modelos finalistas quando houver componentes estocásticos e recursos disponíveis.
6. Avaliar o fold 10 uma única vez para cada configuração final congelada.
7. Selecionar e congelar o candidato a validação externa antes de consultar suas métricas no dataset externo escolhido. Confirmar, antes da avaliação, que essa base não foi usada no pré-treinamento ou no ajuste do checkpoint selecionado.
8. Na multiclasse, reportar accuracy, balanced accuracy, precision macro, recall macro, F1 macro, F1 weighted, métricas por classe e matriz de confusão. Na multilabel, reportar AUC macro, AUC por classe e Fmax; métricas dependentes de limiar só serão apresentadas com limiares definidos no treino ou na validação. Em ambas, registrar tempo e custo computacional.

Com maior disponibilidade de processamento, será possível manter sinais e caches processados em memória, executar modelos nas configurações originais e reduzir gargalos de leitura. O ambiente efetivamente utilizado, a versão de cada repositório, as seeds e as configurações de execução serão registrados. Maior capacidade computacional não será usada para ampliar indefinidamente o espaço de busca, que permanecerá previamente delimitado.

8. Melhoria dos modelos clássicos

- Usar records500 como configuração principal do TCC II, preservando records100 como referência histórica e modo de depuração.
- Manter os atributos estatísticos já implementados e avaliar descritores espectrais simples; atributos morfológicos ou de variabilidade só serão incluídos se extraídos de forma confiável e testável.
- Revisar pipelines de imputação, escala, seleção de atributos e pesos de classe, todos ajustados exclusivamente no treino.
- Comparar sem balanceamento, class_weight e SMOTE somente no treino; não assumir que SMOTE produz melhoria uniforme.
- Aplicar busca pequena e reproduzível no fold 9, com orçamento equivalente entre modelos e F1 macro como critério principal.
- Registrar tempo, memória, parâmetros, métricas por classe e dispersão entre sementes para os modelos estocásticos finalistas.

9. Recomendação e auditoria da base de validação externa

A Georgia permanece como a base mais indicada para a validação externa neste TCC II por combinar ECGs de 12 derivações, 10 segundos, 500 Hz, acesso público e origem populacional distinta do PTB-XL. A escolha somente será confirmada após auditoria de rótulos, cobertura por classe, qualidade dos sinais, diferenças de domínio e compatibilidade com a formulação multilabel. Se o modelo final utilizar pré-treinamento que inclua Georgia, outro checkpoint ou outra base externa independente deverá ser selecionado.

Base candidata	Potencial para o projeto	Limitação principal	Papel possível
Georgia	ECGs de 12 derivações em 500 Hz, formato próximo ao PTB-XL e mapeamento diagnóstico viável.	Rótulos multi-label em SNOMED-CT ainda exigem auditoria e mapeamento para as cinco superclasses.	Recomendação principal para validação externa, condicionada à auditoria.
CODE-15%	Base brasileira ampla, pública e relevante para discutir aplicabilidade nacional.	Os rótulos disponíveis não cobrem diretamente todas as superclasses MI, STTC e HYP.	Continuidade futura, pré-treinamento ou análise brasileira parcial.
MIMIC-IV-ECG	Grande escala, 12 derivações e origem institucional distinta.	Construção dos rótulos e eventual ligação com dados clínicos aumentam o custo e a complexidade de acesso.	Alternativa futura de alta força científica, caso a rotulagem seja viável.
ICBEB2018	Já é contemplada pelo benchmark oficial e favorece reprodução e transferência.	As classes originais não correspondem diretamente às cinco superclasses atuais.	Benchmark secundário ou análise de transferência.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

Recomenda-se ao orientador aprovar a Georgia como primeira opção, condicionada a auditoria e a ausência de contaminação pelo pré-treinamento. CODE-15% oferece relevância brasileira e grande escala, mas seu espaço de rótulos não corresponde diretamente a todas as superclasses; MIMIC-IV-ECG é valiosa para pré-treinamento, mas exige acesso e construção de rótulos; ICBEB2018 favorece comparação com o benchmark original, embora utilize classes diferentes. A decisão final registrará versão, licença, frequência, duração, sistema de rótulos, suporte por classe, origem populacional e eventual participação da base em pré-treinamentos.

10. Escopo mínimo para conclusão do TCC II

Escopo obrigatório

(1) pipeline multilabel auditado e referência multiclasse preservada; (2) cinco modelos clássicos reavaliados; (3) benchmark original de Helme reproduzido com pelo menos os representantes convolucionais principais e recorrente bidirecional; (4) TCN, S4 e ECG-JEPA executados como extensões centrais; (5) seleção por validação e teste interno consultado apenas após congelamento; (6) dataset externo selecionado, auditado e mantido fora de treino e pré-treinamento; (7) validação externa do candidato congelado; (8) SHAP/LIME no tabular e Integrated Gradients no profundo; (9) métricas, custo, variabilidade, texto e apresentação consolidados.

Extensões condicionais

ProtoECGNet, Wavelet+NN quando não concluída na reprodução principal, segunda base externa, ensembles, ST-MEM, PatchECG, HeartLang, ECG-FM, ECGFounder e avaliação com médicos somente serão considerados depois do escopo obrigatório e mediante concordância do orientador.

11. Plano de execução orientado por entregas

A execução será conduzida por entregas verificáveis, e não por semanas rígidas. Cada atividade poderá ser antecipada assim que seus pré-requisitos estiverem satisfeitos; tarefas independentes, como auditoria da base externa, preparação do ambiente e documentação, poderão ocorrer em paralelo. A referência interna de outubro permanece apenas como margem de segurança, sem impedir a conclusão antecipada de qualquer bloco.

Etapa	Atividade	Entrega/verificação	Pode iniciar quando
1	Preservar o TCC I e inventariar código, resultados, checkpoints e dados.	Marco do TCC I identificável; inventário e checklist de integridade.	Imediatamente.
2	Fixar protocolo multilabel, métricas, folds, seeds e regras de seleção.	Protocolo versionado e aprovado; testes que impedem uso indevido do fold 10.	Imediatamente, em paralelo a etapa 1.
3	Auditar Georgia e alternativas externas, incluindo rótulos e sobreposição com pré-treinamento.	Matriz de decisão e dataset externo selecionado ou contingência acionada.	Imediatamente; independe dos treinamentos.
4	Preparar caches, ambiente, rastreamento de experimentos e pipeline multilabel.	Smoke test reproduzível com treino 1-8, validação 9 e teste 10 bloqueado.	Após a definição preliminar do protocolo.
5	Reproduzir os modelos originais de Helme em 100 Hz.	Resultados de validação comparáveis ao benchmark e origem do código registrada.	Quando o pipeline multilabel passar nos smoke tests.

Etapa	Atividade	Entrega/verificação	Pode iniciar quando
6	Reavaliar modelos clássicos e atributos em 500 Hz.	Busca controlada, artefatos e melhores configurações escolhidas no fold 9.	Quando os caches e pipelines tabulares estiverem prontos; pode ocorrer em paralelo a etapa 5.
7	Integrar e validar TCN.	Arquitetura testada, histórico salvo e resultado de validação registrado.	Após a etapa 4; pode ocorrer em paralelo aos demais modelos.
8	Integrar e validar S4.	Arquitetura testada, custo medido e resultado de validação registrado.	Após a etapa 4 e verificação das dependências específicas.
9	Integrar ECG-JEPA e auditar os dados usados no checkpoint.	Regime de transferência documentado; validação registrada; ausência de contaminação externa confirmada.	Após a etapa 3 definir qual base deverá permanecer externa.
10	Executar sementes finalistas e congelar configurações.	Ranking de validação, variabilidade, custo e manifestos dos finalistas.	Quando cada família obrigatória tiver ao menos uma execução válida.
11	Avaliar fold 10 e, depois, executar a validação externa uma única vez.	Métricas internas e externas finais, sem reajuste posterior pelos resultados externos.	Somente após congelamento formal dos modelos e do mapeamento de rótulos.
12	Executar interpretabilidade, consolidar artefatos e atualizar texto/apresentação.	SHAP/LIME, Integrated Gradients, tabelas, figuras e versão completa para revisão.	Pode iniciar com modelos congelados; redação metodológica pode ser adiantada desde a etapa 2.

12. Entregáveis e critérios de aceite

Entregavel	Critério mínimo de aceite
Protocolo e ambiente reproduzíveis	Dependências, seeds, hardware, commits, folds, métricas e comandos registrados; teste bloqueado durante seleção.
Relatório da base externa	Comparação das candidatas, escolha justificada, licença, rótulos, distribuição, limitações e sobreposição com pré-treinamento auditadas.
Baselines clássicos	Cinco modelos executados sob orçamento comparável, sem vazamento e com resultados salvos.
Benchmark de Helme	Implementações originais selecionadas reproduzidas em multilabel/100 Hz, com commit e adaptações documentados.
Extensões modernas	TCN, S4 e ECG-JEPA executados sob protocolo comum, com custo, validação e limitações registrados.
Avaliação interna	Configurações congeladas pela validação; fold 10 usado somente para avaliação final; tarefas apresentadas separadamente.

Entregavel	Critério mínimo de aceite
Validação externa	Modelo congelado aplicado sem tuning externo e sem contaminação por pré-treinamento; harmonização e mudança de domínio reportadas.
Interpretabilidade	SHAP/LIME vinculados ao modelo tabular e Integrated Gradients ao melhor profundo, sem afirmacoes de causalidade clínica.
TCC II e apresentação	Texto, tabelas, figuras, referencias e slides coerentes com resultados reais e com as decisões aprovadas.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

13. Riscos, decisões e critérios de redução de escopo

Risco/decisão	Impacto	Mitigação proposta
Escopo excessivo	Muitos repositórios podem impedir análise e redação adequadas.	Manter TCN, S4 e ECG-JEPA como extensões centrais; modelos fundacionais maiores e ProtoECGNet permanecem condicionais.
Recursos computacionais insuficientes	Treinamentos ou múltiplas sementes excedem o tempo disponível.	Benchmark antecipado, checkpoints e retomada; cortar primeiro variações, buscas adicionais e sementes excedentes.
Incompatibilidade entre implementações	Repositórios usam frequências, formatos e bibliotecas diferentes.	Criar adaptadores mínimos, registrar commits e separar reprodução original de extensões locais.
Contaminação da validação externa	O dataset externo pode ter participado do pré-treinamento do checkpoint.	Auditar a origem do checkpoint; usar checkpoint sem a base externa ou selecionar outra base independente.
Dataset externo sem cobertura adequada	A avaliação das superclasses pode ficar incompleta ou artificial.	Congelar o mapeamento antes da inferência e acionar a alternativa aprovada se a cobertura for insuficiente.
Comparação entre tarefas ou entradas diferentes	Resultados podem ser interpretados como efeito isolado do algoritmo.	Separar multiclasse de multilabel e registrar representação, frequência, pré-treinamento e protocolo de cada configuração.
Tuning excessivo	Sobreajuste ao fold 9 e atraso da execução.	Definir orçamento e espaço de busca antes dos experimentos; não reformular a busca após observar o teste.
Licenças ou pesos indisponíveis	Uma implementação moderna pode não ser reutilizável no prazo.	Verificar licença e checkpoint antes da integração; CPC e implementações abertas funcionam como contingência.
Avaliação com médicos	Prazo, protocolo e exigências éticas incompatíveis com o escopo mínimo.	Manter como continuidade; iniciar apenas com orientação formal e viabilidade institucional.
Base brasileira incompatível	A relevância geográfica pode exigir mudança indevida do problema.	Usar CODE-15% em objetivo complementar ou pré-treinamento, sem forçar equivalência de rótulos.

Fonte: elaboração dos autores a partir do projeto e das referências técnicas indicadas.

14. Referências técnicas para o planejamento

- STRODTHOFF, N. et al. Deep Learning for ECG Analysis: Benchmarks and Insights from PTB-XL. IEEE Journal of Biomedical and Health Informatics, 2021.
- Repositório oficial ecg_ptb-xl_benchmarking: https://github.com/helme/ecg_ptb-xl_benchmarking
- PTB-XL no PhysioNet: <https://physionet.org/content/ptb-xl/1.0.3/>
- PhysioNet/Computing in Cardiology Challenge e Georgia: <https://physionet.org/content/challenge-2020/1.0.2/>

- CODE-15% no Zenodo: <https://zenodo.org/records/4916206>
- MIMIC-IV-ECG no PhysioNet: <https://physionet.org/content/mimic-iv-ecg/1.0/>
- Repositório de aprendizado autossupervisionado em ECG: <https://github.com/tmehari/ecg-selfsupervised>
- Repositório S4 para ECG: https://github.com/tmehari/ssm_ecg
- Repositório ECG-JEPA: <https://github.com/kweimann/ECG-JEPA>
- Repositório ProtoECGNet: <https://github.com/bbj-lab/protoecgnet>

15. Encaminhamento

Solicita-se a validação do orientador quanto a seis decisões: (1) adoção da formulação multilabel como trilha principal, mantendo a multiclasse do TCC I como referência; (2) reprodução das arquiteturas supervisionadas de Helme e inclusão de TCN, S4 e ECG-JEPA como extensões centrais; (3) aplicação de SHAP/LIME ao melhor modelo tabular e Integrated Gradients ao melhor modelo profundo, mantendo ProtoECGNet como opcional; (4) Georgia como primeira candidata externa, condicionada a auditoria, harmonização e ausência de sobreposição com pré-treinamento; (5) modelos fundacionais maiores, segunda base externa e avaliação com médicos fora do escopo obrigatório; e (6) execução orientada por entregas, com redução de escopo apenas segundo os critérios registrados. Após essa validação, o plano poderá ser transposto para o formulário institucional do TCC II.

Orientador	Comentários / aprovação:
Alunos	Ajustes acordados:
Data	____ / ____ / 2026